

Preparación PAES


Clase 18: Análisis de Datos y Medidas de Tendencia Central



Tu fórmula para el éxito

Eje Probabilidad y Estadística

Análisis de Datos



La **estadística descriptiva** es una rama de la matemática que emplea métodos y técnicas que se utilizan en la recolección, ordenamiento, resumen, análisis, interpretación y comunicación de un conjunto de datos de una determinada población de interés.

La **población** es un conjunto de individuos o elementos que poseen alguna variable cualitativa o cuantitativa (característica) común que se quiere estudiar. Las poblaciones pueden ser finitas o infinitas. Por lo general la población de interés suele ser de gran tamaño y por lo tanto su estudio requeriría de mucho tiempo y recursos. Es por ello que se suele tomar una **muestra**.

Una **muestra** es un subconjunto de la población, que idealmente nos sirve de referencia para hacernos una idea de lo que pasa con esa población. Una buena muestra es aquella que logre representar o parecerse en sus características a la población completa y que por tanto nos permite hacer inferencias de la misma, sin tener el registro de todos sus individuos. Este tipo de muestra es la que conocemos como **muestra representativa**.

Una **encuesta** es una forma de recabar información, la cual se realiza sobre la muestra (o sobre la población), con el fin de obtener opiniones, características, mediciones, etc.

Tabulación de datos

Cuando recabamos la información, ésta debe ser ingresada en tablas para que su interpretación sea más simple. A este proceso se le llama tabulación de datos. Dependiendo del tipo y características de los datos (variables cualitativas o variables cuantitativas), estos se pueden tabular en tablas sin intervalos o con intervalos, según las necesidades del caso.

Variables Cuantitativas: Son aquellas que se pueden contar o medir. Las variables cuantitativas se dividen a su vez en:


- *Continuas:* Son aquellas que pueden tomar cualquier valor real, tales como la estatura, la masa, el tiempo de espera en una fila, etc.
- *Discretas:* Son aquellas que tienen restricciones numéricas, por ejemplo: el número de hijos (no podemos tener 3,87 hijos), la cantidad de amigos, etc.

Variables Cualitativas: Son aquellas que obedecen a características no numéricas de la población. Se dividen en:

- *Ordinales:* Son variables que se pueden jerarquizar y dar un orden. Por ejemplo: Nivel Socioeconómico, Nivel educacional, Rango militar, etc.
- *Nominales:* Son características sin una jerarquía, tales como el nombre de una persona, el color favorito, etc.

Eje Probabilidad y Estadística

Análisis de Datos



Tablas de frecuencias para datos no agrupado.

Variable. Es una característica de la población que resulta de interés. Ésta puede ser cualitativa o cuantitativa.

Dato(x). Corresponde a un valor de la variable.

Frecuencia o frecuencia absoluta (f). Número de veces que se repite el dato.

Frecuencia acumulada o Frecuencia absoluta acumulada (F). Esta frecuencia tiene utilidad cuando estudiamos variables cuantitativas o cualitativas ordinales. Se obtiene sumando las frecuencias de todos los valores inferiores o iguales al valor considerado, es decir, se suman ordenadamente las frecuencias absolutas hasta la que ocupa la última posición. El valor de la última frecuencia acumulada corresponde al total de datos (n).

Frecuencia relativa (fr). Se obtiene dividiendo la frecuencia absoluta por el total de datos. Se puede expresar en fracción, decimal o porcentaje. Para expresar en porcentaje, el cociente obtenido se multiplica por 100 y recibe el nombre de frecuencia porcentual o frecuencia relativa porcentual.

Frecuencia relativa acumulada (Fr). Se obtiene sumando las frecuencias relativas de todos los valores inferiores o iguales al valor considerado, es decir, se suman ordenadamente las frecuencias relativas hasta la que ocupa la última posición. El valor de la última frecuencia relativa acumulada es siempre 1; si está expresada en porcentaje, será 100%.

Rango. Es la diferencia entre el valor máximo y el valor mínimo de los datos.


Cantidad de datos (n). Se obtiene sumando las frecuencias absolutas.

x	f	F	fr	Fr
1	2	2	20%	20%
2	3	5	30%	50%
3	5	10	50%	100 %

$n = 10$

Eje Probabilidad y Estadística

Análisis de Datos



Tablas de frecuencias para datos agrupados en intervalos

Intervalo. Representa un conjunto de números que se encuentran entre dos valores dados, llamados límites del intervalo.

Límite inferior y límite superior del intervalo. Son los límites izquierdo y derecho respectivamente de cada intervalo. Éstos pueden o no estar incluidos en el intervalo, dependiendo de cada ejercicio.

Amplitud de un intervalo. Es la diferencia entre el límite superior y el límite inferior del intervalo independiente del tipo de intervalo.

Marca de clase (MC). Es un valor que representa al intervalo y se calcula promediando los límites de dicho intervalo; es decir, se suman los límites inferior y superior, y el resultado se divide en dos. Cada intervalo tendrá su propia marca de clase.

Frecuencia o frecuencia absoluta (f). Cantidad de datos que se encuentran en el intervalo.

Rango. No existe universalidad en el cálculo del rango en tablas con intervalos, ya que al no conocer específicamente los valores de los datos, existe más de un método para determinar una buena aproximación para este (por ejemplo: diferencia entre la mayor y la menor marca de clase; o diferencia entre el mayor límite superior y el menor límite inferior de los intervalos). No obstante lo anterior, siempre podremos asegurar que el rango será menor o igual que la diferencia entre el límite superior del último intervalo y el límite inferior del primer intervalo.

Intervalo	MC	f
[0 , 100[	50	20
[100 , 200[	150	30
[200 , 300[	250	50

Eje Probabilidad y Estadística

Análisis de Datos



Representación gráfica e interpretación de gráficos

La representación gráfica de una distribución de frecuencias nos permite ver de manera clara y ordenada un determinado estudio estadístico. Hay varios tipos de gráficos, siendo los más comunes: histogramas, gráfico de barras, polígono de frecuencias o gráfico de líneas y gráfico de torta o circular.

Histograma





Gráfico de barras



Poligonal de frecuencias o gráfico de líneas





Gráfico circular o de torta




Eje Probabilidad y Estadística

Análisis de Datos

Histogramas

Son gráficos que se usan para representar datos agrupados en intervalos.




Intervalo	f	MC
]130 , 140]	12	135
]140 , 150]	14	145
]150 , 160]	16	155
]160 , 170]	10	165



Gráfico de Barras

El gráfico de barras, a diferencia del histograma, se usa para representar variables cuantitativas discretas, y variables cualitativas, razón por la cual pueden estar las barras separadas.



Eje Probabilidad y Estadística

Análisis de Datos

Polígono de frecuencias

El gráfico poligonal de frecuencias, nos permite representar lo mismo que un gráfico de barras, pero tiene como principal ventaja, que se pueden mostrar dos o más poblaciones de manera simultánea. Es por tanto un gráfico muy útil para comparar.






Gráfico de Torta o Circular.

El gráfico circular tiene por objeto mostrar proporcionalmente cuál es la porción de la población (círculo completo) asociada a cada valor (o categoría) de la variable de estudio. El ángulo del centro de cada sector circular es directamente proporcional a la cantidad de elementos en cada categoría.



Eje Probabilidad y Estadística

Medidas de Tendencia Central: Datos no agrupados



Las medidas de tendencia central son indicadores que intentan centralizar en un valor único la información de una población o muestra. Estas son: La **Media aritmética** (o promedio), la **Moda** y la **Mediana**.

- **Media**

La media aritmética o promedio aritmético ($\bar{X}$), es el cociente entre la suma de todos los datos y el número de datos. Si se tienen n datos: $x_1, x_2, x_3, \dots, x_n$, su media aritmética es:

$$\bar{x} = \frac{\sum_{i=1}^n x_i}{n} = \frac{x_1 + x_2 + x_3 + x_4 + \dots + x_n}{n}$$

- **Moda**

Es el valor del dato que más se repite. Un conjunto de datos puede tener 1 moda (Unimodal), más de una moda (Polimodal o Multimodal) o no tener moda (Amodal).

- El conjunto $\{ 2, 3, 4, 4, 6, 6, 6, 8, 9 \}$ tiene una moda igual a 6.
- El conjunto $\{ 2, 3, 4, 4, 6, 6, 8, 8, 9 \}$ tiene más de una moda: 4, 6, y 8.
- El conjunto $\{ 2, 2, 4, 4, 9, 9 \}$ no tiene moda, ya que no hay dato que se repita más que el resto.

- **Mediana**

La mediana de un conjunto de datos ordenados de menor a mayor, corresponde al valor que divide al conjunto de datos en dos: la mitad mayor y la mitad menor. Se puede interpretar que la mitad de los datos es menor o igual a la mediana, y que la mitad de los datos es mayor o igual a la mediana. Si se tienen n datos, se tienen dos posibilidades:

- Para **n impar**: la mediana corresponde al dato que ocupa la posición central de los datos.
- Para **n par**: la mediana corresponde al promedio entre los dos datos centrales.

Eje Probabilidad y Estadística

Medidas de Tendencia Central: Datos agrupados



Media

La media aritmética o promedio ($\bar{x}$) se calcula sumando todos los productos entre la marca de clase y la frecuencia respectiva de cada intervalo, para luego dividir este resultado por el número total de datos. Si se tienen n datos, que se dividen en k intervalos distintos con marcas de clase:

$MC_1, MC_2, MC_3, \dots, MC_k$ y frecuencias $f_1, f_2, f_3, \dots, f_k$, la media aritmética se calcula:

$$\bar{x} = \frac{\sum_{i=1}^k MC_i \cdot f_i}{n} = \frac{MC_1 f_1 + MC_2 f_2 + MC_3 f_3 + \dots + MC_k f_k}{n}$$

Intervalo modal

En el caso de las tablas con datos agrupados en intervalos, no conocemos el valor de cada dato, solo sabemos la cantidad de datos que se encuentran en cada intervalo. Por esta razón, no podemos conocer el dato que más se repite, es decir no podemos determinar la moda; solo podemos conocer el o los intervalos con mayor frecuencia., llamado “intervalo modal”.

Intervalo que contiene a la mediana

El intervalo que contiene a la mediana corresponde al intervalo que contiene al dato en la posición central o a los dos datos centrales, dependiendo si la cantidad de datos es impar o par, respectivamente. Por lo tanto, para determinar este intervalo, se debe calcular $n/2$ y buscar el intervalo que tiene el dato que ocupa esa posición, usando la Frecuencia acumulada. Si $n/2$ resulta un número decimal, este se aproxima al entero mayor más cercano.